

Workshop de Letramento Estatístico

Conceitos Estatísticos Básicos

Laboratório de Estatística Aplicada – UFRN

13 de outubro de 2026

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
CENTRO DE CIÊNCIAS EXATAS E DA TERRA
DEPARTAMENTO DE ESTATÍSTICA

O que é Estatística?

O que é Estatística?

A Estatística envolve:

- coleta;
- organização;
- análise;
- interpretação de dados.

Seu objetivo é obter informação a partir dos dados.

Aplicações em diversas áreas:

- medicina;
- psicologia;
- engenharia;
- biologia.

Usada para descrever os dados. Organiza, classifica e apresenta as informações por meio de:

- gráficos,
- tabelas,
- coeficientes (medidas-resumo).

Qualquer análise estatística deve começar com uma **análise descritiva (ou exploratória)**.

Processo de generalização a partir de resultados particulares, ou seja, inferir propriedades do todo com base em uma parte.

- Mais complexa que a Estatística Descritiva, porém essencial;
- A generalização envolve sempre uma margem de incerteza;
- Essa incerteza é tratada por técnicas fundamentadas na teoria da probabilidade.

Amostragem

- **População:** Conjunto de elementos que possuem alguma característica em comum;
- **Amostra:** Um subconjunto da população

Amostragem Probabilística

Amostragem probabilística é aquela em que todos os elementos da população possuem uma probabilidade conhecida e diferente de zero de serem selecionados.

- Garante maior representatividade;
- Permite calcular erros amostrais;
- Fundamenta técnicas de inferência estatística.

Principais tipos:

- **Aleatória simples**
- **Estratificada**
- **Sistemática**
- **Por conglomerados**

Amostragem Não Probabilística

Amostragem não probabilística ocorre quando a seleção dos elementos não se baseia em probabilidades conhecidas.

- Depende do julgamento ou conveniência do pesquisador;
- Não permite calcular erros amostrais;
- Menor capacidade de generalização dos resultados.

Principais tipos:

- **Amostragem por conveniência**
- **Amostragem por julgamento**
- **Amostragem por quotas**
- **Bola de neve**

Tipos de Variável

- É uma característica medida ou observada em cada elemento da população (ou amostra);
- Valores variam de elemento para elemento;
- Podem ser classificadas em qualitativas ou quantitativas.

Variáveis qualitativas

- Representam descrição ou qualidade;
- São classificadas em nominal e ordinal;
 - Nominal: Sem ordem natural (ex: sexo, estado civil, cor do olho);
 - Ordinal: Com ordem natural (ex: escolaridade, grau de satisfação com algum serviço).

- São de natureza numérica;
- São classificadas em discreta e contínuas;
 - Discreta: resultante de contagens (ex: número de filhos, peças defeituosas em um lote);
 - Contínuas: provenientes de mensuração; estão dentro de um intervalo (ex: peso, altura, renda mensal)

- **Dado:** Valor observado/medido de uma variável em um elemento do estudo;
- **Observação:** valores observados/medidos de todas as variáveis em um elemento do estudo.

Medidas de Posição e Dispersão

- Nos orientam a respeito da localização espacial dos dados;
- Exemplos: Média, Moda, Mediana, Quartis e Percentis.

Medidas de Posição - Média

- Se temos n observações em uma determinada variável $X = x_1, x_2, \dots, x_n$, definimos a média aritmética como sendo:

$$\bar{X} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n}$$

- Exemplo: Considere as notas de 5 alunos em uma prova:

6.7, 8.0, 7.6, 9.1, 10.0

A média aritmética $\bar{X}$ é:

$$\bar{X} = \frac{6.7 + 8.0 + 7.6 + 9.1 + 10.0}{5} = \frac{41.4}{5} = 8.3$$

Medidas de Posição - Mediana (caso ímpar)

- Se temos n observações em uma determinada variável $X = x_1, x_2, \dots, x_n$, definimos a mediana como sendo o valor que divide as observações ao meio quando estão em ordem crescente.
- **Exemplo:** Considere as notas de 5 alunos em uma prova:

6.7, 8.0, 7.6, 9.1, 10.0

Colocando em ordem crescente:

6.7, 7.6, 8.0, 9.1, 10.0

Como há $n = 5$ observações (ímpar), a mediana é o valor central: 8

Medidas de Posição - Mediana (caso par)

- Agora, suponha que um novo aluno fez a prova e tirou nota 9.5. As notas passam a ser:

6.7, 8.0, 7.6, 9.1, 10.0, 9.5

Colocando em ordem crescente:

6.7, 7.6, 8.0, 9.1, 9.5, 10.0

Como há $n = 6$ observações (par), a mediana é a média dos dois valores centrais:

$$\frac{8.0 + 9.1}{2} = 8.55$$

Medidas de Posição - Moda

- Se temos n observações em uma determinada variável $X = x_1, x_2, \dots, x_n$, definimos a moda como sendo o valor que ocorre com maior frequência
- Pode haver:
 - uma moda (**unimodal**);
 - duas modas (**bimodal**);
 - mais de duas modas (**multimodal**);
 - ou nenhuma moda (quando todos os valores são diferentes).
- **Exemplo:** Considere as notas de 6 alunos:

6.7, 7.6, 8.0, 8.0, 9.1, 10.0

O valor que mais se repete é: 8.0

Medidas de Posição - Primeiro Quartil (Q_1)

- Se temos n observações em uma variável $X = x_1, x_2, \dots, x_n$, o primeiro quartil (Q_1) é o valor que deixa um quarto das observações abaixo dele e três quartos acima.
- Para determinar Q_1 , primeiro colocamos os dados em ordem crescente e calculamos a posição teórica:

$$\frac{(n + 1)}{4}$$

- O valor de Q_1 será a observação que ocupa essa posição na ordem crescente.

Exemplo: Cálculo do Primeiro Quartil (Q_1)

- Considere as notas (em ordem crescente):

6.7, 7.6, 8.0, 9.1, 9.5, 10.0

Temos $n = 6$ observações.

- Calculamos a posição teórica:

$$\frac{(6 + 1)}{4} = 1.75 \approx 2$$

- Portanto o primeiro quartil é a segunda observação da amostra

Medidas de Posição - Terceiro Quartil (Q_3)

- Se temos n observações em uma variável $X = x_1, x_2, \dots, x_n$, o terceiro quartil (Q_3) é o valor que deixa três quartos das observações abaixo dele e um quarto acima.
- Para determinar Q_3 , primeiro colocamos os dados em ordem crescente e calculamos a posição teórica:

$$\frac{3 \times (n + 1)}{4}$$

- O valor de Q_3 será a observação que ocupa essa posição na ordem crescente

Exemplo: Terceiro Quartil (Q_3)

- Considere as notas em ordem crescente:

6.7, 7.6, 8.0, 9.1, 9.5, 10.0

com $n = 6$ observações.

- Calculamos a posição teórica de Q_3 :

$$\frac{3 \times (n + 1)}{4} = 5.25 \approx 5$$

- Portanto, o terceiro quartil é a quinta observação da amostra

- Nos orientam a respeito da variabilidade dos dados
- Exemplos: Amplitude, Variância, Desvio Padrão, Coeficiente de Variação

Medidas de Dispersão - Amplitude

- A amplitude é a diferença entre o maior e o menor valor de um conjunto de dados.
- Fórmula:

$$A = X_{\text{máx}} - X_{\text{mín}}$$

- Exemplo: considere as notas

6.7, 7.6, 8.0, 9.1, 9.5, 10.0

O maior valor é 10.0 e o menor é 6.7, então:

$$A = 10.0 - 6.7 = 3.3$$

Medidas de Dispersão - Variância

- A variância mede o quanto os valores de um conjunto de dados se afastam da média.
- Para um conjunto de n observações $X_1, X_2, \dots, X_n$, a variância amostral é calculada por:

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

- Exemplo: considere as notas dos 6 alunos:

6.7, 7.6, 8.0, 9.1, 9.5, 10.0

A média é:

$$\bar{X} = \frac{6.7 + 7.6 + 8.0 + 9.1 + 9.5 + 10.0}{6} = 8.48$$

- Aplicando a fórmula:

$$S^2 = \frac{(6.7 - 8.48)^2 + (7.6 - 8.48)^2 + \dots + (10.0 - 8.48)^2}{6 - 1} = 1.58$$

Medidas de Dispersão - Desvio Padrão

- O desvio padrão é definido como a raiz quadrada da variância. Ele mede o grau de dispersão dos valores em relação à média, utilizando a mesma unidade da variável.

- Fórmula:

$$S = \sqrt{S^2}$$

- Exemplo: considerando as notas dos alunos cujo cálculo da variância resultou em

$$S^2 = 1.58$$

o desvio padrão é dado por:

$$S = \sqrt{1.58} \approx 1.26$$

Medidas de Dispersão - Coeficiente de Variação

- O coeficiente de variação (CV) é definido como:

$$CV = \frac{S}{\bar{X}} \times 100\%$$

- Ele expressa a variabilidade dos dados em relação à média.
- O CV é expresso em termos percentuais e é adimensional, permitindo comparações entre grandezas de naturezas diferentes.
- Exemplo: considerando as notas dos alunos com média $\bar{X} = 8.48$ e desvio padrão $S \approx 1.26$:

$$CV = \frac{1.26}{8.48} \times 100\% \approx 14.82\%$$

Conhecendo o R

O que é o R?

- Linguagem de programação apropriada para análise estatística
- Gratuita e disponível para os principais sistemas operacionais
- Permite personalizações e amplia a reprodutibilidade das análises;
- Diferente de softwares como Excel ou SPSS, documenta todos os passos da análise (limpeza, preparação e resultados)
- Uma das linguagens mais usadas em Ciência de Dados, junto com Python e Julia


O que é o Rstudio?

- RStudio é um ambiente de desenvolvimento integrado para a linguagem R
- Facilita escrever, executar e organizar códigos em R
- Disponível em versão gratuita (open-source) e profissional (paga)

Onde baixar o R e o RStudio

- Acesse: <https://posit.co/download/rstudio-desktop/>
- Permite baixar o R diretamente via CRAN e o Rstudio
- Disponível para Windows, macOS e Linux
- Quem não puder ou não quiser instalar, pode usar uma solução na nuvem: <https://posit.cloud/>

Conhecendo o ambiente do Rstudio



- Permite escrever e editar scripts (sequência de comandos a serem executados pelo R)
- Facilita a organização dos comandos
- Oferece destaque de sintaxe
- É uma das partes mais utilizadas do RStudio

- Exibe a maioria dos resultados dos comandos
- Permite digitar comandos diretamente, sem usar o editor de código
- Ideal para testes rápidos e experimentos
- Pode ser usado para chamar ajuda do R com o comando ?

- No Environment ficam todos os objetos criados na sessão do R
- Sessão: período entre abrir e fechar o R, utilizando memória e processador
- A aba History guarda o histórico de comandos utilizados

Files, Plots, Packages, Help e Viewer

- Files: Navegação de arquivos do computador e definição do diretório de trabalho
- Plots: Exibe gráficos gerados e permite exportação para formatos como .png e .pdf
- Packages: Lista pacotes instalados, permite carregar, instalar ou atualizar pacotes
- Help: Fornece documentação e ajuda sobre funções e pacotes
- Viewer: Visualiza conteúdo web local, gráficos interativos ou outputs de RMarkdown/Shiny

Princípios básicos de programação

Você pode usar o R para fazer cálculos matemáticos básicos

```
1 / 200 * 30
```

```
#> [1] 0.15
```

```
(59 + 73 + 2) / 3
```

```
#> [1] 44.66667
```

```
sin(pi / 2)
```

```
#> [1] 1
```

Você pode criar novos objetos com o operador de atribuição `<-`:

```
x <- 3 * 4
```

Note que o valor de `x` não é impresso, ele é apenas armazenado.
Se você quiser ver o valor, digite `x` no console.

Princípios básicos de programação

Você pode combinar vários elementos em um vetor com `c()`:

```
primos <- c(2, 3, 5, 7, 11, 13)
```

E a aritmética básica em vetores é aplicada a cada elemento do vetor:

```
primos * 2
#> [1]  4  6 10 14 22 26
primos - 1
#> [1]  1  2  4  6 10 12
```

Todos os comandos em R onde você cria objetos, comandos de atribuição, têm a mesma forma:

```
nome_objeto <- valor
```

Comentários

O R ignorará qualquer texto após `#` em uma linha. Isso permite que você escreva comentários, que são textos que são ignorados pelo R, mas que podem ser lidos por outros humanos.

```
# cria um vetor de números primos  
primos <- c(2, 3, 5, 7, 11, 13)
```

```
# multiplica primos por 2  
primos * 2  
#> [1]  4  6 10 14 22 26
```

Para código de análise de dados, use comentários para explicar sua abordagem estratégica e registrar informações importantes à medida que as encontrar.

A importância dos nomes

Nomes de objetos devem começar com letra e conter apenas letras, e números. Use nomes descritivos e uma convenção para várias palavras. Recomendamos snake_case, onde você separa palavras minúsculas com "_".

Alguns exemplos:

`eu_uso_snake_case`

`outrasPessoasUsamCamelCase`

`algumas.pessoas.usam.pontos`

`E_aLgumas.Pessoas_nAoUsamConvencao`

A importância dos nomes

Você pode ver o conteúdo de um objeto (chamaremos isso de inspecionar) digitando seu nome:

```
x  
#> [1] 12  
r_rocks <- 2^3  
r_rock  
#> Error: object 'r_rock' not found  
R_rocks  
#> Error: object 'R_rocks' not found
```

O R fará os cálculos chatos para você, mas em troca, você deve escrever suas instruções de forma precisa. Se não, você provavelmente receberá um erro que diz que o objeto que você está procurando não foi encontrado.

Como Montar um Banco de Dados de Qualidade para Uso no R

Como Montar um Banco de Dados de Qualidade para Uso no R

Passo 1: Definir o objetivo da base de dados

- O que você quer analisar?
- Quais variáveis são necessárias?

Como Montar um Banco de Dados de Qualidade para Uso no R

Passo 2: Planejar as variáveis

Crie uma lista com:

- Nome da variável
- Tipo (numérica, categórica, data, texto)
- Unidade de medida (se for numérica)
- Possíveis categorias (se for qualitativa)

Dica: prefira nomes simples e sem espaços, como: *idade*, *pesokg*, *sexo*, *especie*.

Como Montar um Banco de Dados de Qualidade para Uso no R

Passo 3: Organizar a base no formato “retangular”

O formato ideal para o R é o “**tidy data**”:

- Cada linha = 1 observação
- Cada coluna = 1 variável
- Cada célula = 1 valor

Como Montar um Banco de Dados de Qualidade para Uso no R

	state	color	food	age	height	score
Jane	NY	blue	Steak	30	165	4.6
Niko	TX	green	Lamb	2	70	8.3
Aaron	FL	red	Mango	12	120	9.0
Penelope	AL	white	Apple	4	80	3.3
Dean	AK	gray	Cheese	32	180	1.8
Christina	TX	black	Melon	33	172	9.5
Cornelia	TX	red	Beans	69	150	2.2

Como Montar um Banco de Dados de Qualidade para Uso no R

Passo 4: Padronizar nomes das variáveis

No R, evite:

- Espaços (altura do animal)
- Acentos (peso_médio)
- Caracteres especiais

Como Montar um Banco de Dados de Qualidade para Uso no R

Passo 5: Padronizar categorias das variáveis qualitativas

Errado:

- "Masculino", "Macho", "M", "macho", "masculino"

Correto:

- "m" / "f", "masculino" / "feminino"

Escolha uma forma e mantenha sempre igual.

Como Montar um Banco de Dados de Qualidade para Uso no R

Passo 6: Escolher o formato de arquivo

Os melhores formatos para usar com R:

- **CSV (.csv)**
- **TXT delimitado por tab**
- **Excel (.xlsx)**

Como Montar um Banco de Dados de Qualidade para Uso no R

Passo 7: Validar a base

Antes de usar no R, cheque:

- Não existem linhas duplicadas
- Todas as variáveis estão com o tipo correto
- Categorias padronizadas
- Nomes adequados
- Nenhum número onde deveria ser texto (e vice-versa)